



(12) 发明专利申请

(10) 申请公布号 CN 120597195 A

(43) 申请公布日 2025. 09. 05

(21) 申请号 202510667716.5

(22) 申请日 2025.05.22

(71) 申请人 南京邮电大学

地址 210023 江苏省南京市栖霞区文苑路9号

(72) 发明人 蒋杰 许世杰 罗启瑞 周正  
牛一童 桂林卿 郭政鑫

(51) Int.Cl.

G06F 18/25 (2023.01)

A61B 5/11 (2006.01)

G08B 21/04 (2006.01)

G08B 29/18 (2006.01)

G06F 18/2131 (2023.01)

G06F 18/15 (2023.01)

G06V 40/20 (2022.01)

G06V 10/80 (2022.01)

G06V 10/82 (2022.01)

G06N 3/045 (2023.01)

G06N 3/0464 (2023.01)

G06N 3/048 (2023.01)

G06N 3/08 (2023.01)


权利要求书2页 说明书6页 附图2页

(54) 发明名称

基于多尺度SE-SK网络的跌倒检测方法

(57) 摘要

本发明提供了一种使用超宽带雷达检测独居老年人跌倒的方法,即基于多尺度SE-SK网络的跌倒检测方法。该方法利用三个特征维度进行三分支评估。首先,对雷达回波进行预处理,得到距离-时间(RT)、距离-多普勒(RD)和时间-多普勒(TD)特征谱。接下来,构建两个分支以确定特征图是否指示跌倒。然后,实现多尺度SE-SK网络(MSESK网络)以进行特征评估。通过整合三个特征图的输出并使用投票机制,该方法能够精准地判断人员是否发生了跌倒。



1. 基于多尺度SE-SK网络的跌倒检测方法,其特征在于:包括以下步骤,

S1、采集人员在室内场景下的多种动作的脉冲超宽带 (IR-UWB) 雷达回波信号,对其进行预处理,并提取其在距离-多普勒 (RD)、时间-多普勒 (TD)、距离-时间 (RT) 域上的多普勒特征谱,将获得特征谱数据作为样本数据,并标注活动类别标签后,获得数据集,将数据集划分得到训练集和测试集;

S2、构建由挤压激励-选择性核网络 (Squeeze Excitation Selective Kernel网络,缩写为SE-SK网络) 和CNN网络组成的多尺度SE-SK网络 (MSESK网络) 模型,将样本数据输入MSESK网络,其中分别将TD谱输入CNN网络,将RD、RT谱输入SESK网络;

S3、利用训练集的样本数据和活动类别标签训练构建的CNN网络和MSESK网络参数,获得训练后的CNN和SESK网络;

S4、将测试集的样本数据输入训练后的MSESK网络中,输出人体跌倒的识别效果。

2. 如权利要求1所述的基于多尺度SE-SK网络的跌倒检测方法,其特征在于,所述步骤S1包括:

S11. 采用滑动平均法 (RUN) 抑制TD谱的背景杂波:

$$C(m+1, n) = \alpha C(m, n) + (1 - \alpha) X(m, n)$$

其中,  $C$  表示背景杂波信号,  $m$  是距离索引,  $n$  是时间索引,  $\alpha$  为杂波抑制因子,取值范围为0.8至0.95,  $X(m, n)$  为原始雷达回波矩阵;

S12. 采用向量均值消除法 (VMC) 抑制RD谱与RT谱的静态杂波,计算背景杂波均值:

$$C(m, n) = \frac{1}{M} \sum_{m=1}^M X(m, n)$$

然后去除静态背景:

$$Y(m, n) = X(m, n) - \frac{1}{M} \sum_{m=1}^M X(m, n)$$

其中,  $Y(m, n)$  为杂波抑制后的信号矩阵,通过逐列均值消除固定干扰;

S13. TD谱生成:

对RUN处理后的信号应用短时傅里叶变换 (STFT):

$$Y_{TD}(f_d) = \sum_{l=-L/2}^{L/2} Y(m+l, n) \cdot w(l) \cdot e^{-j2\pi \frac{f_d}{f_r} l}$$

其中:  $w(l)$  为长度为  $L$  的高斯窗函数,  $l$  表示时间点,  $L$  取32至64点以平衡时频分辨率,  $f_d$  为多普勒频率,  $f_r$  为脉冲重复频率,  $Y_{TD}(f_d)$  表示短时傅里叶变换结果;

S14. RD谱生成:

对VMC处理后的信号沿慢时间维度进行FFT:

$$Y_{RD}(k, n) = \sum_{m=1}^M Y(m, n) \cdot e^{-j2\pi \frac{m}{M} k}$$

其中,  $k$  为多普勒单元索引,  $Y_{RD}(k, n)$  表示傅里叶变换结果;并通过阈值分割滤除噪声;

$$\mathbf{Y}_{\text{RD}}(k, n) = \begin{cases} \mathbf{Y}_{\text{RD}}(k, n), & \mathbf{Y}_{\text{RD}}(k, n) \geq a \\ 0, & \text{其他} \end{cases}$$

其中, 阈值 $a = \mu + b\sigma$ ,  $\mu$ 为特征谱均值,  $\sigma$ 为标准差,  $b$ 为经验系数, 取值为2至3;

S15. RT谱生成: 直接提取杂波抑制后的距离-时间矩阵 $Y(m, n)$ , 并通过滑动窗口提取动态轨迹。

3. 如权利要求1所述的基于多尺度SE-SK网络的跌倒检测方法, 其特征在于, 所述CNN分支的结构包括:

输入层: TD、RD、RT谱分别归一化为 $224 \times 224$ 像素的灰度图像;

层级设计: 3层卷积模块, 每层包含:

卷积核:  $3 \times 3$ , 步长1, 填充1, 通道数分别为16、32、64;

批归一化 (BN): 减少内部协变量偏移;

激活函数: ReLU, 增强非线性表达能力;

最大池化:  $2 \times 2$ 池化窗口, 步长2, 降低特征图分辨率至 $112 \times 112$ 、 $56 \times 56$ 、 $28 \times 28$ ;

全局平均池化: 将最终特征图 ( $28 \times 28 \times 64$ ) 压缩为64维特征向量。

4. 如权利要求1所述的基于多尺度SE-SK网络的跌倒检测方法, 其特征在于, 所述SE-SK分支的结构包括:

SE模块:

对输入特征进行全局平均池化, 生成通道描述向量;

通过两层全连接层及Sigmoid函数生成通道权重 $W_{\text{SE}}$ :

$$W_{\text{SE}} = \text{Sigmoid}(\text{FC}(\text{ReLU}(\text{FC}(F_{\text{avg}}))))$$

将通道权重与原始特征逐通道相乘, 增强有效特征;

SK模块:

使用 $3 \times 3$ 和 $5 \times 5$ 两种卷积核并行提取多尺度特征;

通过注意力机制计算各尺度特征的权重、 $W_{\text{SK}}$ :

$$W_{\text{SK}} = \text{Softmax}(\text{FC}(\text{GAP}(F_{\text{multi}})))$$

加权融合多尺度特征, 生成最终输出。

5. 如权利要求1所述的基于多尺度SE-SK网络的跌倒检测方法, 其特征在于, 所述方法还包括模型训练步骤:

S41. 采集960组跌倒样本和960组非跌倒样本, 按5:1比例划分为训练集和测试集;

S42. 使用交叉熵损失函数和Adam优化器进行训练, 学习率设置为0.01;

S43. 通过五折交叉验证优化网络参数, 直至模型收敛。

## 基于多尺度SE-SK网络的跌倒检测方法

### 技术领域

[0001] 本发明涉及一种基于多尺度SE-SK网络的IR-UWB雷达人体跌倒检测方法,属于非接触式医疗监护与雷达信号处理技术领域。

### 技术背景

[0002] 近年来,随着非接触式医疗监护技术的快速发展,基于雷达信号的人体行为感知成为研究热点。其中,脉冲超宽带(IR-UWB)雷达因其高分辨率、强穿透性及隐私保护特性,在人体跌倒检测中展现出显著优势。通过分析雷达回波信号的时间-多普勒谱、距离-时间谱等多维度特征,可实现对人体跌倒动作的精准感知。

[0003] 然而,现有基于IR-UWB雷达的跌倒检测方法仍存在局限性。传统方法依赖单分支网络结构,仅能提取单一特征谱(如时间-多普勒谱),难以捕捉跌倒动作的完整动态信息。此外,多特征谱融合过程中缺乏对目标独特特征的针对性提取,导致特征丢失,检测精度下降。例如,基于支持向量机(SVM)或卷积神经网络(CNN)的单一模型,虽在部分场景下有效,但受限于静态特征提取或动态时序建模不足,难以适应复杂环境下的跌倒检测需求。

[0004] 现有技术中,如中国发明专利CN106921407B.公开的一种基于单UWB雷达的跌倒检测方法,采用静态特征提取与单分支网络结合,虽降低了系统成本,但未解决动态跌倒过程中多尺度特征关联性问题,导致误检率较高。

[0005] 上述问题表明,如何在单雷达系统中高效融合多尺度动态特征、减少信息损失,并提升复杂场景下的检测鲁棒性,是当前IR-UWB雷达人体跌倒检测领域亟需突破的技术瓶颈。

### 发明内容

[0006] 本发明的目的是提供一种基于多尺度SE-SK网络的IR-UWB雷达人体跌倒检测方法,解决现有技术中单分支网络特征提取不完整、多特征融合信息丢失导致的检测精度低、环境鲁棒性差的问题。其中,SE-SK网络的全称是挤压激励-选择性核网络,英文全称为Squeeze Excitation Selective Kernel。

[0007] 本发明的技术解决方案是:基于多尺度SE-SK网络的IR-UWB雷达人体跌倒检测方法,包括以下步骤,

[0008] S1、使用IR-UWB雷达采集人体动作回波信号,通过滑动平均法(RUN)和向量均值消除法(VMC)分别处理时间-多普勒(TD)、距离-多普勒(RD)及距离-时间(RT)域的信号,生成三组特征谱,构建数据集并按比例划分为训练集与测试集;

[0009] 具体的,采集人员在室内场景下的多种动作的脉冲超宽带(IR-UWB)雷达回波信号,对其进行预处理,并提取其在距离-多普勒(RD)、时间-多普勒(TD)、距离-时间(RT)域上的多普勒特征谱,将获得特征谱数据作为样本数据,并标注活动类别标签后,获得数据集,将数据集划分得到训练集和测试集。

[0010] S2、设计双分支多尺度SE-SK网络:CNN分支通过3层卷积提取TD谱的时频特征;SE-

SK分支利用通道注意力(SE模块)与多尺度卷积融合(SK模块)处理RD/RT谱,特征拼接后经全连接层输出分类概率;

[0011] 具体的,构建由挤压激励-选择性核网络(Squeeze Excitation Selective Kernel网络,缩写为SE-SK网络)和CNN网络组成的多尺度SE-SK网络(MSESK网络)模型,将样本数据输入MSESK网络,其中分别将TD谱输入CNN网络,将RD、RT谱输入SESK网络。

[0012] S3、利用训练集的样本数据和活动类别标签训练构建的CNN网络和MSESK网络参数,获得训练后的CNN和SESK网络;

[0013] 具体的,采用加权交叉熵损失(权重系数2.5)和Adam优化器(学习率0.001)训练网络,结合L2正则化与Dropout防止过拟合,训练100个epoch至收敛。

[0014] S4、将测试集的样本数据输入训练后的MSESK网络中,基于双分支投票机制输出人体跌倒的识别效果。

[0015] 进一步的,步骤S1包括:

[0016] S11.使用单IR-UWB雷达(如X4M03型号)采集人体动作回波信号。对静态杂波抑制,使用滑动平均法(RUN)对时间-多普勒谱(TD)进行动态背景建模,抑制TD谱的背景杂波:

[0017]  $C(m+1, n) = \alpha C(m, n) + (1 - \alpha) X(m, n)$

[0018] 其中,C表示背景杂波信号,m是距离索引,n是时间索引, $\alpha$ 为杂波抑制因子,取值范围为0.8至0.95,X(m,n)为原始雷达回波矩阵。

[0019] S12.采用向量均值消除法(VMC)抑制RD谱与RT谱的静态杂波,针对距离-多普勒谱(RD)与距离-时间谱(RT),计算背景杂波均值:

[0020] 
$$C(m, n) = \frac{1}{M} \sum_{m=1}^M X(m, n)$$

[0021] 然后去除静态背景:杂波抑制后的信号为:

[0022] 
$$Y(m, n) = X(m, n) - \frac{1}{M} \sum_{m=1}^M X(m, n)$$

[0023] 其中,Y(m,n)为杂波抑制后的信号矩阵,通过逐列均值消除固定干扰;

[0024] S13.特征谱生成分为TD谱、RD谱、RT谱,生成步骤如下:

[0025] TD谱生成:对RUN处理后的信号应用短时傅里叶变换(STFT):

[0026] 
$$Y_{TD}(f_d) = \sum_{l=-L/2}^{L/2} Y(m+l, n) \cdot w(l) \cdot e^{-j2\pi \frac{f_d l}{f_r}}$$

[0027] 其中:w(l)为长度为L的高斯窗函数,l表示时间点,L取32至64点以平衡时频分辨率, $f_d$ 为多普勒频率, $f_r$ 为脉冲重复频率, $Y_{TD}(f_d)$ 表示短时傅里叶变换结果。

[0028] S14.RD谱生成:

[0029] 对VMC处理后的信号沿慢时间维度进行FFT:

[0030] 
$$Y_{RD}(k, n) = \sum_{m=1}^M Y(m, n) \cdot e^{-j2\pi \frac{m}{M} k}$$

[0031] 其中,k为多普勒单元索引, $Y_{RD}(k, n)$ 表示傅里叶变换结果;

[0032] 并通过阈值分割滤除噪声:

$$[0033] \quad \mathbf{Y}_{RD}(k, n) = \begin{cases} \mathbf{Y}_{RD}(k, n), & \mathbf{Y}_{RD}(k, n) \geq a \\ 0, & \text{其他} \end{cases}$$

[0034] 其中, 阈值  $a = \mu + b\sigma$ ,  $\mu$  为特征谱均值,  $\sigma$  为标准差,  $b$  为经验系数, 取值为 2 至 3。

[0035] S15.RT谱生成: 直接提取杂波抑制后的距离-时间矩阵  $Y(m, n)$ , 并通过滑动窗口提取动态轨迹。

[0036] 进一步的, 步骤 S2 中, 网络整体架构由以下结构构成:

[0037] 输入层: TD、RD、RT 谱分别归一化为  $224 \times 224$  像素的灰度图像;

[0038] 双分支结构: 专用于处理 TD 谱的时频动态特征的 CNN 分支和融合 RD 与 RT 谱的空间-多普勒特征 SE-SK 分支;

[0039] 投票决策层: 集成双分支输出, 通过多数表决机制判定是否发生跌倒。

[0040] 其中 CNN 分支细节:

[0041] 层级设计: 3 层卷积模块, 每层包含:

[0042] 卷积核:  $3 \times 3$ , 步长 1, 填充 1, 通道数分别为 16、32、64。

[0043] 批归一化 (BN): 减少内部协变量偏移。

[0044] 激活函数: ReLU, 增强非线性表达能力。

[0045] 最大池化:  $2 \times 2$  池化窗口, 步长 2, 降低特征图分辨率至  $112 \times 112$ 、 $56 \times 56$ 、 $28 \times 28$ 。

[0046] 全局平均池化: 将最终特征图 ( $28 \times 28 \times 64$ ) 压缩为 64 维特征向量。

[0047] 其中 SE-SK 分支细节:

[0048] SE 模块对输入特征进行全局平均池化, 生成通道描述向量;

[0049] 通过两层全连接层及 Sigmoid 函数生成通道权重  $W_{SE}$ :

$$[0050] \quad W_{SE} = \text{Sigmoid}(\text{FC}(\text{ReLU}(\text{FC}(F_{avg}))))$$

[0051] 将通道权重与原始特征逐通道相乘, 增强有效特征;

[0052] 具体由以下步骤构成:

[0053] 1) 压缩 (Squeeze): 对输入特征图 ( $H \times W \times C$ ) 沿空间维度进行全局平均池化, 生成通道描述向量  $z$ , 其中  $H$  是特征图的高度,  $W$  是特征图的宽度,  $C$  是通道数。

[0054] 2) 激励 (Excitation): 通过两层全连接 (FC) 学习通道权重:

$$[0055] \quad s = \sigma(W_2 \cdot \delta(W_1 \cdot z))$$

[0056] 其中, 权重  $W_1 \in \mathbb{R}^{C/r \times C}$ , 权重  $W_2 \in \mathbb{R}^{C \times C/r}$ , 压缩比  $r$  为 16,  $\delta$  为 ReLU 函数,  $\sigma$  为 Sigmoid 函数。

[0057] 3) 特征加权: 将权重向量  $s$  与原始特征逐通道相乘, 得到增强特征图。

[0058] SK 模块使用  $3 \times 3$  和  $5 \times 5$  两种卷积核并行提取多尺度特征;

[0059] 通过注意力机制计算各尺度特征的权重  $W_{SK}$ :

$$[0060] \quad W_{SK} = \text{Softmax}(\text{FC}(\text{GAP}(F_{\text{multi}})))$$

[0061] 加权融合多尺度特征, 生成最终输出;

[0062] 具体由以下步骤构成:

[0063] 1) 多尺度卷积: 并行执行  $3 \times 3$  与  $5 \times 5$  卷积, 输出特征图  $U_1$ 、 $U_2$ 。

[0064] 2) 特征融合:

[0065] 拼接  $U_1$  与  $U_2$ , 通过全连接层生成注意力权重  $a \in [0, 1]$ :

[0066] 加权融合特征:

[0067]  $\tilde{U} = a \cdot U_1 + (1 - a) \cdot U_2$

[0068] 特征融合层:将RD与RT谱的特征图在通道维度拼接,通过 $1 \times 1$ 卷积(通道数64)降维,输出 $64 \times 28 \times 28$ 特征图。

[0069] 进一步的,步骤S2中,投票决策机制由以下步骤进行:

[0070] 若CNN分支输出为“跌倒”,或SE-SK分支对RD谱和RT谱的检测结果中至少一个为“跌倒”,则判定为跌倒事件;否则判定为正常活动。

[0071] 具体的,分支输出:每个分支通过全连接层输出二分类结果(0:非跌倒,1:跌倒)。

[0072] 多数表决:若总预测跌倒数 $\geq 2$ (即至少两个分支判定为跌倒),则最终判定为跌倒;否则为非跌倒。

[0073] 进一步的,步骤S3中,网络训练与优化的步骤如下:

[0074] 损失函数采用加权交叉熵损失函数 $\mathcal{L}$ ,平衡跌倒与非跌倒样本的不均衡分布:

$$[0075] \quad \mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [\lambda y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

[0076] 其中, $\lambda$ 为跌倒样本权重(实验设定 $\lambda=2.5$ ), $y_i$ 为真实标签, $p_i$ 为预测概率, $N$ 为样本数。

[0077] 优化策略采用优化器:Adam,初始学习率0.001,每20个epoch衰减为原值的0.5。同时正则化使用L2权重衰减(系数 $1e-4$ ),Dropout率0.3。训练批次为32,总epoch数为100。

[0078] 进一步的,步骤S4中,测试与部署的步骤如下:

[0079] 首先实时采集雷达信号,经预处理后输入训练好的模型,投票机制输出结果,再结合时间连续性约束(如连续3帧检测为跌倒才触发报警),降低瞬时噪声干扰。

## 附图说明

[0080] 图1为本发明实施例适用于基于多尺度SE-SK网络的IR-UWB雷达人体跌倒检测方法的流程图;

[0081] 图2为实施例中静态杂波抑制说明示意图;

[0082] 图3为实施例中MSESK网络运作说明示意图;

[0083] 图4为实施例中各个方法效果比较。

## 具体实施方式

[0084] 为了使本发明的内容更容易被清楚地理解,下面根据具体实施例并结合附图,对本发明作进一步详细的说明。

[0085] 一种基于多尺度SE-SK网络的IR-UWB雷达人体跌倒检测方法,包括如下步骤:

[0086] S1、使用IR-UWB雷达采集人体动作回波信号,通过滑动平均法(RUN)和向量均值消除法(VMC)分别处理时间-多普勒谱(TD)、距离-多普勒谱(RD)及距离-时间谱(RT),生成三组特征谱,构建数据集并按比例划分为训练集与测试集。

[0087] S2、设计双分支多尺度SE-SK网络:CNN分支通过3层卷积提取TD谱的时频特征;SE-SK分支利用通道注意力(SE模块)与多尺度卷积融合(SK模块)处理RD/RT谱,特征拼接后经全连接层输出分类概率。

[0088] S3、采用加权交叉熵损失(权重系数2.5)和Adam优化器(学习率0.001)训练网络,结合L2正则化与Dropout防止过拟合,训练100个epoch至收敛。

[0089] S4、测试集输入训练模型后,基于双分支投票机制输出结果,准确率达97%,支持实时检测(单帧 $\leq 20\text{ms}$ ),适用于家庭、养老院等低功耗场景部署。

[0090] 以下将对本发明所提供的一种基于多尺度SE-SK网络的IR-UWB雷达人体跌倒检测方法,进行详细说明。

[0091] 图1为本发明实施例适用于基于多尺度SE-SK网络的IR-UWB雷达人体跌倒检测方法的流程图。

[0092] 在步骤1中,使用X4M03型号IR-UWB雷达(功耗118mW)在 $10\text{m} \times 10\text{m}$ 室内场景中采集人体动作回波信号。雷达安装高度为2.15米,水平距离测试区域2.4米,发射高斯脉冲信号。

[0093] 图2为静态杂波抑制的示意图。

[0094] 时间-多普勒谱(TD)预处理:采用滑动平均法(RUN)抑制动态背景杂波:

[0095]  $C(m+1, n) = \alpha C(m, n) + (1 - \alpha) X(m, n)$

[0096] 其中,  $\alpha = 0.8$ ,  $x(m, n)$  为原始回波矩阵。

[0097] 距离-多普勒谱(RD)与距离-时间谱(RT)预处理采用向量均值消除法(VMC)消除静态杂波:

[0098] 
$$C(m, n) = \frac{1}{M} \sum_{m=1}^M X(m, n)$$

[0099] 杂波抑制后信号为:  $Y(m, n) = X(m, n) - C(m, n)$

[0100] TD谱生成:对RUN处理后的信号进行短时傅里叶变换(STFT):

[0101] 
$$Y_{TD}(f_d) = \sum_{l=-L/2}^{L/2} Y(m+l, n) \cdot w(l) \cdot e^{-j2\pi \frac{f_d}{f_r} l}$$

[0102] 窗口函数 $w(l)$ 为高斯窗(长度为64,重叠率50%)。

[0103] 对VMC处理后的信号沿慢时间维度进行快速傅里叶变换(FFT)从而获得RD谱:

[0104] 
$$Y_{RD}(k, n) = \sum_{m=1}^M Y(m, n) \cdot e^{-j2\pi \frac{m}{M} k}$$

[0105] 并通过阈值分割( $\mu + b\sigma$ ,  $b=3$ )滤除噪声。

[0106] 直接提取VMC处理后的距离-时间矩阵 $Y(m, n)$ ,获得RT谱,作为动态运动轨迹特征。

[0107] 在步骤2中,构建多尺度SE-SK网络(MSESK),如图3所示。CNN分支输入TD谱。ReLU激活层为了增强非线性表达能力。全局平均池化:输出16维特征向量。

[0108] SE-SK分支(输入RD与RT谱):

[0109] SE模块:

[0110] 全局平均池化生成通道描述向量 $z$ ,全连接层(压缩比 $r=16$ )与Sigmoid函数生成通道权重,加权输出特征图

[0111]  $s = \sigma(W_2 \cdot \delta(W_1 \cdot z))$

[0112] SK模块:

[0113] 并行 $3 \times 3$ 与 $5 \times 5$ 卷积核提取多尺度特征,输出特征图 $U1$ 、 $U2$ 。

[0114] 通过注意力机制融合特征,将双分支输出特征拼接后输入全连接层,输出分类概率。

[0115] 在步骤3中,进行模型训练与优化:

[0116] 采集960组跌倒与非跌倒样本,按5:1划分为训练集(800组/类)与测试集(160组/类)。损失函数设置为交叉熵损失函数,加权系数 $\lambda=2.5$ 以平衡样本不均衡。优化器为Adam,初始学习率0.01,每10个epoch衰减为0.5倍。正则化为L2权重衰减(系数为0.0001),Dropout率0.3。训练周期为50个epoch,批次大小32。验证策略为五折交叉验证,优化网络参数直至收敛。

[0117] 步骤4为跌倒检测与投票机制:

[0118] 测试阶段通过输入测试集数据,获取双分支输出:

[0119] CNN分支输出TD谱分类结果(0/1);SE-SK分支输出RD与RT谱分类结果(各为0/1)。投票机制为若双分支中至少两个判定为“跌倒”(即总预测值 $\geq 2$ ),则判定为跌倒事件;否则为正常活动。

[0120] 如图4所示,本发明性能验证准确率为97%(对比单分支CNN的95.8%)。鲁棒性:在10dB低信噪比下准确率保持95%以上。实时性为单帧处理时间 $\leq 20\text{ms}$ 。




图1




图2




图3

| 方法          | CNN   | CNN-LSTM | Capsule Network | SVM    | MSESK |
|-------------|-------|----------|-----------------|--------|-------|
| IR-UWB 设备数量 | 1     | 3        | 1               | 2      | 1     |
| 摔倒样本数量      | 336   | 60060    | 18701490        | 400    | 960   |
| 准确度         | 95.8% | 96.9%    | 91.0%           | 95.95% | 97.0% |

图4