



(12) 发明专利申请

(10) 申请公布号 CN 120983044 A

(43) 申请公布日 2025. 11. 21

(21) 申请号 202511101924.5

A61B 5/355 (2021.01)

(22) 申请日 2025.08.07

A61B 5/366 (2021.01)

G06N 3/04 (2023.01)

(71) 申请人 哈尔滨工业大学

地址 150001 黑龙江省哈尔滨市南岗区西
大直街92号

(72) 发明人 张甲 任子熙 段展 周圳涛

(74) 专利代理机构 黑龙江龙权知识产权代理有
限公司 23224

专利代理师 姜有维

(51) Int. Cl.

A61B 5/318 (2021.01)

A61B 5/346 (2021.01)

A61B 5/0507 (2021.01)

A61B 5/00 (2006.01)

A61B 5/353 (2021.01)


权利要求书2页 说明书6页 附图2页

(54) 发明名称

一种基于FMamba神经网络的非接触式心电图生成方法

(57) 摘要

本发明涉及生命体征监测技术领域,更具体的说是一种基于FMamba神经网络的非接触式心电图生成方法,步骤S1:对接收来雷达数据进行处理,从雷达数据中提取出心脏的心跳微动信号;步骤S2:利用最大重叠离散小波变换(MODWT)对输入的心跳微动信号进行多层次分解;步骤S3:多层次分别采用嵌入网络(Embedding)将其映射至高维特征空间,并输入到独立的FMamba神经网络模块进行序列特征提取;步骤S4:FMamba神经网络模块内的Frequent SSM(FSSM)模块进行自适应变间距扫描,针对各个层级的不同频段进行自适应变间距的扫描,得到 M_0 ;可以非接触式生成心电图,适用于远程医疗监控、车载健康系统及居家养老等应用场景。



1. 一种基于FMamba神经网络的非接触式心电图生成方法,其特征在于:该方法包括以下步骤:

步骤S1:对接收来雷达数据进行处理,从雷达数据中提取出心脏的心跳微动信号;

步骤S2:利用最大重叠离散小波变换 (MODWT) 对输入的心跳微动信号进行多层级分解;

步骤S3:多层级分别采用嵌入网络 (Embedding) 将其映射至高维特征空间,并输入到独立的FMamba神经网络模块进行序列特征提取;

步骤S4:FMamba神经网络模块内的Frequent SSM (FSSM) 模块进行自适应变间距扫描,针对各个层级的不同频段进行自适应变间距的扫描,得到 M_0 。

2. 根据权利要求1所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特征在于:所述步骤S2中,最大重叠离散小波变换 (MODWT) 将每个心跳微动信号分解为多个程度上的细节信号和低频信号部分;

即: $X_t = \sum_{j=1}^N D_{j,t} + S_{N,t}$ 其中 $D_{j,t}$ 和 $S_{N,t}$ 分别代表第 $j=1,2,3,\dots,N$ 层得到的细节信号和

第N层平滑信号进行反变换得到的重建信号分量,即原始心跳微动信号是所有尺度下细节成分和最底层平滑成分的总和。

3. 根据权利要求2所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特征在于:所述心跳微动信号的N级分解,其中第j层的心跳微动信号对应系数的分解公式为:

$$W_{j,t} = \sum_{l=0}^{L_j-1} \tilde{h}_{j,l} X_{(t-l) \bmod N}$$

$$v_{j,t} = \sum_{l=0}^{L_j-1} \tilde{g}_{j,l} X_{(t-l) \bmod N}$$

$W_{j,t}$ 表示第j层的细节系数,反映了频带的快速变化; $v_{j,t}$ 表示第j层的平滑系数,保留了信号的低频成分; $\tilde{h}_{j,l}$ 和 $\tilde{g}_{j,l}$ 分别为归一化过后的高通和低通滤波器系数。

4. 根据权利要求1所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特征在于:所述步骤S3中,将心跳微动信号通过最大重叠离散小波变换 (MODWT) 变换分解为若干层不同尺度的分量 $M_{\text{MODWT}}(k)$, $k \in \{1,2,3,\dots,N\}$,对每一个最大重叠离散小波变换 (MODWT) 分解层级,均采用嵌入网络 (Embedding) 将其映射至高维特征空间,并输入到独立的FMamba神经网络模块进行序列特征提取。

5. 根据权利要求4所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特征在于:每个层级的输入的心脏微动数据 $M_{\text{MODWT}}(k) \in \mathbb{R}^{B \times L \times D}$,B代表批次大小,L代表序列长度,D代表序列维度,输入进入FMamba神经网络模块得到最后的输出 M_0 。

6. 根据权利要求5所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特征在于:在FMamba神经网络模块处理中,首先将输入数进行层归一化处理得到 $\text{LN}(M_{\text{MODWT}}(k))$,提升训练的稳定性,之后 $\text{LN}(M_{\text{MODWT}}(k))$ 数据将通过两个不同的分支进行处理;

其中第一个分支中通过一个线性变换层得到 $\text{Linear}(\text{LN}(M_{\text{MODWT}}(k)))$,在特征维度上做投影,学习到不同特征之间的组合,再经过一个一维卷积层得到 $\text{Conv}(\text{Linear}(\text{LN}(M_{\text{MODWT}}(k))))$ 提取局部时间的上下文信息,由SiLU激活函数处理后引入非线性关系,增强FMamba

神经网络模块学习细微模式的能力。

7. 根据权利要求6所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特征
在于:所述步骤S4中,Frequent SSM (FSSM) 模块引入一种基于频率大小进行变间隔扫描的
策略,一种基于频率大小进行变间隔扫描的策略对于信号中有用的低频信息进行小间隔的
细致扫描,高频无用的多于信息进行大间隔的粗略扫描。

8. 根据权利要求7所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特征
在于:所述一种基于频率大小进行变间隔扫描的策略具体为:对于分解后不同尺度的分量
 $M_{\text{MODWT}}(k)$,其代表一个时间序列 $[x_1, x_2, x_3, \dots, x_k]$,对应的频段为 $[f_{k1}, f_{k2}]$,与函数 $F(f) = a \cdot (f-b)^2 + c$ 做离散积分求均值得到对应扫描间隔 n ;

其中函数中 b 代表中心频率为25Hz, c 代表最小值为1, a 为可学习参数,该函数在心电图
的QRS波段扫描间隔最小,P波段和T波段扫描间隔其次,高频无用噪声波段扫描间隔最大。

9. 根据权利要求8所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特征
在于:所述扫描间隔 n 的公式为:

$$n = \text{round} \left(\frac{1}{f_{k2} - f_{k1}} \int_{f_{k1}}^{f_{k2}} F(f) df \right) \approx \text{round} \left(\sum_i \frac{(F(f_i) + F(f_{i+1})))}{2} \Delta f \right)$$

对初始时间序列 $[x_1, x_2, x_3, \dots, x_k]$ 正向扫描后得到的正向间隔扫描时间序列:

$$X = [x_1, x_{1+n}, x_{1+2n}, \dots, x_{1+jn}]$$

之后再继续进行逆向扫描得到逆向间隔扫描时间序列:

$$X_{\text{inverse}} = [x_k, x_{k-n}, x_{k-2n}, \dots, x_{k-jn}]$$

最后将 X 与 X_{inverse} 输入至Frequent SSM (FSSM) 模块后完成状态空间的建模与融合。

10. 根据权利要求9所述的一种基于Mamba神经网络的非接触式心电图生成方法,其特
征在于: $\text{LN}(M_{\text{MODWT}}(k))$ 数据的第二个分支,输入数据 $\text{LN}(M_{\text{MODWT}}(k))$ 通过线性变换、激活函数
处理后得到 M_i ,与 M_f 做逐元素乘操作 $()$ 后再和原输入 $M_{\text{MODWT}}(k)$ 进行残差相加得到最后输出
 M_o ;整体的数学流程如下所示:

$$M_f = \text{FSSM}(\text{SiLU}(\text{Conv}(\text{Linear}(\text{LN}(M_{\text{MODWT}}(k)))))$$

$$M_i = \text{SiLU}(\text{Linear}(\text{LN}(M_{\text{MODWT}}(k))))$$

$$M_g = M_f \cdot M_i$$

$$M_o = M_{\text{MODWT}}(k) + \text{Linear}(M_g)$$

之后为了充分融合不同时间尺度和频率尺度的信息,将第 N 层的输出 $M_o(N)$ 与第 $N-1$ 层的
最大重叠离散小波变换(MODWT)变换分量 $M_{\text{MODWT}}(N-1)$ 进行拼接(Concat)后,再输入进入第 $N-1$
层的FMamba神经网络模块:

$$M_{\text{input}}(k-1) = \text{Concat}(M_o(k), M_{\text{MODWT}}(k-1)), k \in \{2, 3, \dots, N\}$$

依次类推,最后将第二层的输出 $M_o(2)$ 与第一层的最大重叠离散小波变换(MODWT)变换
分量 $M_{\text{MODWT}}(1)$ 进行拼接后形成多尺度特征融合表示 $M_{\text{input}}(1)$ 并输入FMamba神经网络模块得
到第一层的输出 $M_o(1)$;之后将各层的输出 $M_o(1) \sim M_o(N)$ 进行逆小波变换操作,最终,融合后
的特征会输入到最后一层的FMamba神经网络模块中进行进一步的全局序列建模,并输出为
模拟标准导联心电图的波形序列 M_{output} : $M_{\text{output}} = \text{Mamba}(\text{InverseMODWT}(M_o(1), M_o(2), \dots, M_o(N)))$ 。

一种基于FMamba神经网络的非接触式心电图生成方法

技术领域

[0001] 本发明涉及生命体征监测技术领域,更具体地说是一种基于FMamba神经网络的非接触式心电图生成方法。

背景技术

[0002] 据世界卫生组织(WHO)统计,心血管疾病每年导致约1,790万人死亡,占全球总死亡人数的约32%。心律失常、早期心肌缺血等多种心脏疾病往往在无明显症状的情况下逐渐发展,等到患者感到不适就医时,通常已错过最佳干预时机。研究表明,通过高精度、长时间的心电图(ECG)监测,可以在亚临床阶段及时发现如房颤、早搏等异常,有助于显著降低心肌梗死、脑卒中等重大事件的发生风险。

[0003] 传统心电图信号获取主要依赖于将电极直接贴附在皮肤表面以检测心脏的电生理活动。虽然该方法在临床上应用广泛且测量精度高,但其在实际使用中存在显著局限性,例如不适合长时间连续监测、对皮肤造成粘贴不适以及不便于移动场景下的应用等。

[0004] 研究表明,心脏的电活动与其机械跳动之间存在耦合关系,心电图所记录的电信号变化与胸腔因心脏收缩舒张产生的微小起伏密切相关。这为通过监测胸腔表面因心跳引发的细微位移,间接推断心脏电生理活动、重建类ECG波形提供了理论依据。近年来,非接触式生命体征检测技术成为研究热点,其中超宽带(UWB)雷达因其优异的穿透能力、时间分辨率以及抗干扰特性,已被广泛用于无接触地监测呼吸与心率。然而,如何基于UWB雷达获取的胸腔微动信号,精确捕捉与心电活动紧密对应的机械细节,并从中高保真地还原出关键低频心电成分(如P波、QRS波群、T波),仍面临建模复杂、噪声干扰显著以及序列长期依赖特征难以有效提取等重大挑战。这也是当前非接触式心电图重建领域亟待突破的关键技术瓶颈。

发明内容

[0005] 本发明的目的是提供一种基于FMamba神经网络的非接触式心电图生成方法,可以非接触式生成心电图,适用于远程医疗监控、车载健康系统及居家养老等应用场景。

[0006] 本发明的目的通过以下技术方案来实现:

[0007] 一种基于FMamba神经网络的非接触式心电图生成方法,该方法包括以下步骤:

[0008] 步骤S1:对接收来雷达数据进行处理,从雷达数据中提取出心脏的心跳微动信号;

[0009] 步骤S2:利用最大重叠离散小波变换(MODWT)对输入的心跳微动信号进行多层级分解;

[0010] 步骤S3:多层级分别采用嵌入网络(Embedding)将其映射至高维特征空间,并输入到独立的FMamba神经网络模块进行序列特征提取;

[0011] 步骤S4:FMamba神经网络模块内的Frequent SSM(FSSM)模块进行自适应变间距扫描,针对各个层级的不同频段进行自适应变间距的扫描,得到 M_0 ;

[0012] 所述步骤S2中,最大重叠离散小波变换(MODWT)将每个心跳微动信号分解为多个

程度上的细节信号和低频信号部分；

[0013] 即： $X_t = \sum_{j=1}^N D_{j,t} + S_{N,t}$ ，其中 $D_{j,t}$ 和 $S_{N,t}$ 分别代表第 $j=1,2,3,\dots,N$ 层得到的细节信号和第 N 层平滑信号进行反变换得到的重建信号分量，即原始心跳微动信号是所有尺度下细节成分和最底层平滑成分的总和；

[0014] 所述心跳微动信号的 N 级分解，其中第 j 层的心跳微动信号对应系数的分解公式为：

$$[0015] \quad W_{j,t} = \sum_{l=0}^{L_j-1} \tilde{h}_{j,l} X_{(t-l) \bmod N}$$

$$[0016] \quad v_{j,t} = \sum_{l=0}^{L_j-1} \tilde{g}_{j,l} X_{(t-l) \bmod N}$$

[0017] $W_{j,t}$ 表示第 j 层的细节系数，反映了频带的快速变化； $v_{j,t}$ 表示第 j 层的平滑系数，保留了信号的低频成分； $\tilde{h}_{j,l}$ 和 $\tilde{g}_{j,l}$ 分别为归一化过后的高通和低通滤波器系数；

[0018] 所述步骤S3中，将心跳微动信号通过最大重叠离散小波变换 (MODWT) 变换分解为若干层不同尺度的分量 $M_{\text{MODWT}}(k)$ ， $k \in \{1, 2, 3, \dots, N\}$ ，对每一个最大重叠离散小波变换 (MODWT) 分解层级，均采用嵌入网络 (Embedding) 将其映射至高维特征空间，并输入到独立的FMamba神经网络模块进行序列特征提取；

[0019] 每个层级的输入的心脏微动数据 $M_{\text{MODWT}}(k) \in \mathbb{R}^{B \times L \times D}$ ， B 代表批次大小， L 代表序列长度， D 代表序列维度，输入进入FMamba神经网络模块得到最后的输出 M_0 ；

[0020] 在FMamba神经网络模块处理中，首先将输入数进行层归一化处理得到 $\text{LN}(M_{\text{MODWT}}(k))$ ，提升训练的稳定性，之后 $\text{LN}(M_{\text{MODWT}}(k))$ 数据将通过两个不同的分支进行处理；

[0021] 其中第一个分支中通过一个线性变换层得到 $\text{Linear}(\text{LN}(M_{\text{MODWT}}(k)))$ ，在特征维度上做投影，学习到不同特征之间的组合，再经过一个一维卷积层得到 $\text{Conv}(\text{Linear}(\text{LN}(M_{\text{MODWT}}(k))))$ 提取局部时间的上下文信息，由SiLU激活函数处理后引入非线性关系，增强FMamba神经网络模块学习细微模式的能力；

[0022] 所述步骤S4中，Frequent SSM(FSSM) 模块引入一种基于频率大小进行变间隔扫描的策略，一种基于频率大小进行变间隔扫描的策略对于信号中有用的低频信息进行小间隔的细致扫描，高频无用的多于信息进行大间隔的粗略扫描；

[0023] 所述一种基于频率大小进行变间隔扫描的策略具体为：对于分解后不同尺度的分量 $M_{\text{MODWT}}(k)$ ，其代表一个时间序列 $[x_1, x_2, x_3, \dots, x_k]$ ，对应的频段为 $[f_{k1}, f_{k2}]$ ，与函数 $F(f) = a \cdot (f-b)^2 + c$ 做离散积分求均值得到对应扫描间隔 n ；

[0024] 其中函数中 b 代表中心频率为25Hz， c 代表最小值为1， a 为可学习参数，该函数在心电图的QRS波段扫描间隔最小，P波段和T波段扫描间隔其次，高频无用噪声波段扫描间隔最大；

[0025] 所述扫描间隔 n 的公式为：

$$[0026] \quad n = \text{round} \left(\frac{1}{f_{k2} - f_{k1}} \int_{f_{k1}}^{f_{k2}} F(f) df \right) \approx \text{round} \left(\sum_i \frac{(F(f_i) + F(f_{i+1})))}{2} \Delta f \right)$$

- [0027] 对初始时间序列 $[x_1, x_2, x_3, \dots, x_k]$ 正向扫描后得到的正向间隔扫描时间序列:
- [0028] $X = [x_1, x_{1+n}, x_{1+2n}, \dots, x_{1+jn}]$
- [0029] 之后再继续进行逆向扫描得到逆向间隔扫描时间序列:
- [0030] $X_{\text{inverse}} = [x_k, x_{k-n}, x_{k-2n}, \dots, x_{k-jn}]$
- [0031] 最后将 X 与 X_{inverse} 输入至Frequent SSM (FSSM) 模块后完成状态空间的建模与融合;
- [0032] $\text{LN}(M_{\text{MODWT}}(k))$ 数据的第二个分支,输入数据 $\text{LN}(M_{\text{MODWT}}(k))$ 通过线性变换、激活函数处理后得到 M_i ,与 M_f 做逐元素乘操作 $()$ 后再和原输入 $M_{\text{MODWT}}(k)$ 进行残差相加得到最后输出 M_o ;整体的数学流程如下所示:
- [0033] $M_f = \text{FSSM}(\text{SiLU}(\text{Conv}(\text{Linear}(\text{LN}(M_{\text{MODWT}}(k)))))$
- [0034] $M_i = \text{SiLU}(\text{Linear}(\text{LN}(M_{\text{MODWT}}(k))))$
- [0035] $M_g = M_f \cdot M_i$
- [0036] $M_o = M_{\text{MODWT}}(k) + \text{Linear}(M_g)$
- [0037] 之后为了充分融合不同时间尺度和频率尺度的信息,将第 N 层的输出 $M_o(N)$ 与第 $N-1$ 层的最大重叠离散小波变换 (MODWT) 变换分量 $M_{\text{MODWT}}(N-1)$ 进行拼接 (Concat) 后,再输入进入第 $N-1$ 层的FMamba神经网络模块:
- [0038] $M_{\text{input}}(k-1) = \text{Concat}(M_o(k), M_{\text{MODWT}}(k-1)), k \in \{2, 3, \dots, N\}$
- [0039] 依次类推,最后将第二层的输出 $M_o(2)$ 与第一层的最大重叠离散小波变换 (MODWT) 变换分量 $M_{\text{MODWT}}(1)$ 进行拼接后形成多尺度特征融合表示 $M_{\text{input}}(1)$ 并输入FMamba神经网络模块得到第一层的输出 $M_o(1)$;之后将各层的输出 $M_o(1) \sim M_o(N)$ 进行逆小波变换操作,最终,融合后的特征会输入到最后一层的FMamba神经网络模块中进行进一步的全局序列建模,并输出为模拟标准导联心电图的波形序列 M_{output} : $M_{\text{output}} = \text{Mamba}(\text{InverseMODWT}(M_o(1), M_o(2), \dots, M_o(N)))$ 。
- [0040] 本发明的有益效果为:
- [0041] 本发明面向基于FMamba神经网络模块深度学习的心电图生成方法,将最大重叠离散小波变换 (MODWT) FMamba神经网络模块相结合,通过多尺度小波分解有效分离心脏微动信号的不同频率成分,并设计基于频率的自适应扫描间隔策略,对低频信息进行细致扫描,对高频噪声采用稀疏扫描,有效保留了信号低频有用部分的完整度,提高了心电图中主要低频信号P、QRS、T波重建的保真度与计算效率;
- [0042] 进一步通过逐层特征拼接与级联FMamba神经网络模块实现跨时间尺度和频率尺度的动态依赖耦合,充分利用FMamba神经网络模块在长序列建模中的线性复杂度优势,既增强了对心电图整体波形结构的捕捉能力,又便于在资源受限的边缘设备和可穿戴设备上实时部。

附图说明

- [0043] 下面结合附图和具体实施方法对本发明做进一步详细的说明。
- [0044] 图1是本发明的基于FMamba神经网络的非接触式心电图生成方法示意图;
- [0045] 图2是本发明的FMamba神经网络模块示意图;
- [0046] 图3是本发明的基于频率大小的变间隔扫描策略示意图。

具体实施方式

[0047] 下面结合附图对本发明做进一步详细说明。

[0048] 如图1至图3所示,下面对一种基于FMamba神经网络的非接触式心电图生成方法的步骤和功能进行详细的说明;

[0049] 一种基于FMamba神经网络的非接触式心电图生成方法,该方法包括以下步骤:

[0050] 步骤S1:对接收来雷达数据进行处理,从雷达数据中提取出心脏的心跳微动信号;

[0051] 步骤S2:利用最大重叠离散小波变换 (MODWT) 对输入的心跳微动信号进行多层次分解,如图1所示;

[0052] 为克服最大重叠离散小波变换 (MODWT) 在时间定位和平移不变性上的不足,最大重叠离散小波变换 (MODWT) 省略了滤波过程中的下采样操作,所述步骤S2中,最大重叠离散小波变换 (MODWT) 将每个心跳微动信号分解为多个程度上的细节信号和低频信号部分;

[0053] 即: $X_t = \sum_{j=1}^N D_{j,t} + S_{N,t}$ 其中 $D_{j,t}$ 和 $S_{N,t}$ 分别代表第 $j=1,2,3,\dots,N$ 层得到的细节信号和第 N 层平滑信号进行反变换得到的重建信号分量,即原始心跳微动信号是所有尺度下细节成分和最底层平滑成分的总和;

[0054] 所述心跳微动信号的 N 级分解,其中第 j 层的心跳微动信号对应系数的分解公式为:

$$W_{j,t} = \sum_{l=0}^{L_j-1} \tilde{h}_{j,l} X_{(t-l) \bmod N}$$

[0055]

$$v_{j,t} = \sum_{l=0}^{L_j-1} \tilde{g}_{j,l} X_{(t-l) \bmod N}$$

[0056] $W_{j,t}$ 表示第 j 层的细节系数,反映了频带的快速变化; $v_{j,t}$ 表示第 j 层的平滑系数,保留了信号的低频成分; $\tilde{h}_{j,l}$ 和 $\tilde{g}_{j,l}$ 分别为归一化过后的高通和低通滤波器系数;

[0057] 步骤S3:多层次分别采用嵌入网络 (Embedding) 将其映射至高维特征空间,并输入到独立的FMamba神经网络模块进行序列特征提取;

[0058] 将心跳微动信号通过最大重叠离散小波变换 (MODWT) 变换分解为若干层不同尺度的分量 $M_{\text{MODWT}}(k)$, $k \in \{1,2,3,\dots,N\}$, 进行位置嵌入,对每一个最大重叠离散小波变换 (MODWT) 分解层级,均采用嵌入网络 (Embedding) 将其映射至高维特征空间,对于每个层级的进行位置嵌入后的输入心脏微动数据 $M_{\text{MODWT}}(k) \in \mathbb{R}^{B \times L \times D}$, 输入进入FMamba神经网络模块得到最后的输出 M_0 , FMamba神经网络模块的结构如图2所示;

[0059] 每个层级的输入的心脏微动数据 $M_{\text{MODWT}}(k) \in \mathbb{R}^{B \times L \times D}$, B 代表批次大小, L 代表序列长度, D 代表序列维度, 输入进入FMamba神经网络模块得到最后的输出 M_0 ;

[0060] 在FMamba神经网络模块处理中,首先将输入数进行层归一化处理得到 $\text{LN}(M_{\text{MODWT}}(k))$, 提升训练的稳定性,之后 $\text{LN}(M_{\text{MODWT}}(k))$ 数据将通过两个不同的分支进行处理;

[0061] 其中第一个分支中通过一个线性变换层得到 $\text{Linear}(\text{LN}(M_{\text{MODWT}}(k)))$, 在特征维度上做投影,学习到不同特征之间的组合,再经过一个一维卷积层得到 $\text{Conv}(\text{Linear}(\text{LN}(M_{\text{MODWT}}(k))))$ 提取局部时间的上下文信息,由SiLU激活函数处理后引入非线性关系,增强FMamba神经网络模块学习细微模式的能力;

[0062] 步骤S4:FMamba神经网络模块内的Frequent SSM(FSSM) 模块进行自适应变间距扫描,针对各个层级的不同频段进行自适应变间距的扫描,得到 M_o ;

[0063] Frequent SSM(FSSM) 模块引入一种基于频率大小进行变间隔扫描的策略,一种基于频率大小进行变间隔扫描的策略对于信号中有用的低频信息进行小间隔的细致扫描,高频无用的多于信息进行大间隔的粗略扫描;基于频率大小进行变间隔扫描的策略实施过程如图3所示;该策略能够更好的还原心电图中心电图中低频的P、QRS、T波的频率特征,在保证有效低频信息的完整度的同时,有效避免了无效高频信息带来的冗余采样,提升了特征的获取速率;

[0064] 所述一种基于频率大小进行变间隔扫描的策略具体为:对于分解后不同尺度的分量 $M_{MODWT}(k)$,其代表一个时间序列 $[x_1, x_2, x_3, \dots, x_k]$,对应的频段为 $[f_{k1}, f_{k2}]$,与函数 $F(f) = a \cdot (f-b)^2 + c$ 做离散积分求均值得到对应扫描间隔 n ;

[0065] 其中函数中 b 代表中心频率为25Hz, c 代表最小值为1, a 为可学习参数,该函数在心电图的QRS波段扫描间隔最小,P波段和T波段扫描间隔其次,高频无用噪声波段扫描间隔最大;

[0066] 所述扫描间隔 n 的公式为:

$$[0067] \quad n = \text{round} \left(\frac{1}{f_{k2} - f_{k1}} \int_{f_{k1}}^{f_{k2}} F(f) df \right) \approx \text{round} \left(\sum_i \frac{(F(f_i) + F(f_{i+1}))}{2} \Delta f \right)$$

[0068] 对初始时间序列 $[x_1, x_2, x_3, \dots, x_k]$ 正向扫描后得到的正向间隔扫描时间序列:

$$[0069] \quad X = [x_1, x_{1+n}, x_{1+2n}, \dots, x_{1+jn}]$$

[0070] 之后再逆向扫描得到逆向间隔扫描时间序列:

$$[0071] \quad X_{\text{inverse}} = [x_k, x_{k-n}, x_{k-2n}, \dots, x_{k-jn}]$$

[0072] 最后将 X 与 X_{inverse} 输入至Frequent SSM(FSSM) 模块后完成状态空间的建模与融合;

[0073] $\text{LN}(M_{MODWT}(k))$ 数据的第二个分支,输入数据 $\text{LN}(M_{MODWT}(k))$ 通过线性变换、激活函数处理后得到 M_i ,与 M_f 做逐元素乘操作($\odot$)后再和原输入 $M_{MODWT}(k)$ 进行残差相加得到最后输出 M_o ;整体的数学流程如下所示:

$$[0074] \quad M_f = \text{FSSM}(\text{SiLU}(\text{Conv}(\text{Linear}(\text{LN}(M_{MODWT}(k))))))$$

$$[0075] \quad M_i = \text{SiLU}(\text{Linear}(\text{LN}(M_{MODWT}(k))))$$

$$[0076] \quad M_g = M_f \odot M_i$$

$$[0077] \quad M_o = M_{MODWT}(k) + \text{Linear}(M_g)$$

[0078] 之后为了充分融合不同时间尺度和频率尺度的信息,将第 N 层的输出 $M_o(N)$ 与第 $N-1$ 层的最大重叠离散小波变换(MODWT)变换分量 $M_{MODWT}(N-1)$ 进行拼接(Concat)后,再输入进入第 $N-1$ 层的FMamba神经网络模块:

$$[0079] \quad M_{\text{input}}(k-1) = \text{Concat}(M_o(k), M_{MODWT}(k-1)), k \in \{2, 3, \dots, N\}$$

[0080] 依次类推,最后将第二层的输出 $M_o(2)$ 与第一层的最大重叠离散小波变换(MODWT)变换分量 $M_{MODWT}(1)$ 进行拼接后形成多尺度特征融合表示 $M_{\text{input}}(1)$ 并输入FMamba神经网络模块得到第一层的输出 $M_o(1)$;之后将各层的输出 $M_o(1) \sim M_o(N)$ 进行逆小波变换操作,最终,融合后的特征会输入到最后一层的FMamba神经网络模块中进行进一步的全局序列建模,并输

出为模拟标准导联心电图的波形序列 M_{output} : $M_{\text{output}} = \text{Mamba}(\text{InverseMODWT}(M_o(1), M_o(2), \dots, M_o(N)))$;

[0081] 在本发明的生成式ECG模型训练过程中,采用了Adam优化器,其初始学习率设置为0.001,并使用动态调整策略学习率衰减以保证训练的稳定性和收敛性。损失函数使用L2损失函数,旨在衡量预测结果与实际结果之间的差异,推动模型进行有效优化。此外,Dropout被应用于训练过程中,以防止过拟合并提升模型的泛化能力。训练批次大小设置为32,并根据训练过程中显存使用情况进行调整,每个训练轮次为100轮。数据集使用Nature公开数据集A dataset of clinically recorded radar vital signs with synchronized reference sensor signals,选取所有对象在休息状态下测量得到的ECG与雷达数据,采用R-R间隔误差、QRS间隔误差、P-R间隔误差、Q-T间隔误差衡量模型学习效果,具体结果如表1所示;

[0082] 表1训练结果

[0083]

	R-R间隔	QRS间隔	P-R间隔	Q-T间隔
误差 (ms)	2.8ms	5.4ms	16.6ms	16.4ms
误差百分比 (%)	94%	95%	52%	70%




图1




图2




图3